

 Pontificia Universidad JAVERIANA Bogotá	PONTIFICIA UNIVERSIDAD JAVERIANA Maestría en Inteligencia Artificial Aprendizaje de máquina Taller 1
---	--

Taller 1 – Regresión lineal y logística

Lea con atención el enunciado y realice su entrega teniendo en cuenta los elementos solicitados en las reglas de juego del curso explicadas en la primera sesión, en particular no olvide incluir:

Notebook en formato. **ipynb** desarrollando los elementos pedidos en cada punto. Entregar en carpeta *code*.

Reporte escrito con el análisis de cada punto en un Informe escrito (con pautas IEEE Transactions on Artificial Intelligence). Recuerde escribir introducción a su documento y para cada punto explique su metodología, experimentación, resultados y conclusiones. Realice también conclusiones generales del taller (¿Qué funcionó?, ¿Qué no funcionó?, ¿Qué aprendió?).

Restricción para este taller: Todos los métodos implementados en el taller deben utilizar solamente la librería NumPy, y todos los cálculos deben estar vectorizados. Solo se permite el uso de la librería Pandas, matplotlib o seaborn para cargar los datos, su exploración, visualización, y su conversión en matriz de NumPy. No se permite el uso de otras librerías diferentes a las mencionadas anteriormente.

Caso de estudio: Cultivo de arroz (paddy)

En este caso de estudio se utilizarán datos relacionados con el cultivo de arroz, incluyendo algunas características agronómicas, meteorológicas y propias de cada cultivo.

El dataset se encuentra disponible en UCI Machine Learning Repository:

<https://archive.ics.uci.edu/dataset/1186/paddy+dataset>

Lea la descripción del dataset y de las variables con atención.

Punto 1 (50%)

Utilizando las variables disponibles, cree un modelo de regresión lineal que permita predecir productividad del cultivo. **LA productividad está definida como el rendimiento del arroz (columna Paddy yield(in Kg)) dividido por las hectáreas del cultivo (columna Hectares) . Esta variable no está definida originalmente en el dataset, ud la debe crear.**

Además de la forma de la hipótesis (selección de variables, interacciones, polinomios, transformaciones, tipo de regularización) debe probar diferentes hiper-parámetros de configuración del modelo para obtener una hipótesis adecuada.

Ítems de evaluación

Implementación y validación del método: 10%

Correctitud de la implementación, vectorización, regularización, algoritmo de optimización y verificación de su funcionamiento.

Exploración de datos: 10%

Selección y transformación de variables, construcción de características, decisiones metodológicas y prevención de fuga de información.

Experimentación y selección del modelo: 20%

Comparación metódica de hipótesis, hiperparámetros y sus resultados. Construcción progresiva de mejor hipótesis. Selección justificada del modelo final.

Análisis de resultados y conclusiones: 10%

Interpretación crítica de los resultados, explicación de los efectos observados, identificación de limitaciones y conclusiones sustentadas en evidencia experimental.

Punto 2 (50%)

Utilizando las variables disponibles, cree un modelo de regresión logística que permita predecir la variedad del arroz cultivada. Para que sea un ejercicio de clasificación binaria, tome solamente las variedades CO_43 y Ponmani, descartando las instancias pertenecientes a Delux_Ponni.

Además de la forma de la hipótesis (selección de variables, interacciones, polinomios, transformaciones, tipo de regularización) debe probar diferentes hiper-parámetros de configuración del modelo.

Ítems de evaluación

Implementación y validación del método: 10%

Correctitud de la implementación, vectorización, regularización, algoritmo de optimización y verificación de su funcionamiento.

Exploración de datos: 10%

Selección y transformación de variables, construcción de características, decisiones metodológicas y prevención de fuga de información.

Experimentación y selección del modelo: 20%

Comparación metódica de hipótesis, hiperparámetros y sus resultados. Construcción progresiva de mejor hipótesis. Selección justificada del modelo final.

Análisis de resultados y conclusiones: 10%

Interpretación crítica de los resultados, explicación de los efectos observados, identificación de limitaciones y conclusiones sustentadas en evidencia experimental.